기말고사

1. [용어] 분류 규칙을 학습하는 Decision Tree 는 훈련 데이터에 과도하게 맞춰져서 학습되는 오버피팅 경향이 있어 예측 시, 입력값의 작은 변화에도 결과가 크게 달라져 해결을 못할 수도 있게 된다. 따라서 일반화 성능을 높이기 위해 random forest 가 사용된다. 이는 중복을 허용한 무작위 추출을 통해 여러 개의 학습 데이터 셋을 만들고 여러 개의 결정트리를 만든다. 또 각 결정 트리를 만들 때 전체 feature 를 쓰지 않고 일부 feature 만 랜덤하게 선택해서 분류 기준을 다양화한다. Bootstrapping(부트스트래핑), Ensemble(앙상블), Bagging(배깅), Overfitting(오버피팅)에 대해서 설명해 놓고 해당 용어 써넣기 (PPT 9-1)

2. [용어/계산] Entropy 에 대한 설명: 불확실성을 측정하는 방법 중 하나로 decision tree 에서는 Gini 계수와 더불어 해당 노드의 불순도(클래스가 얼마나 섞여 있는 지)를 측정하는 데 사용되는데 여러 클래스가 균등하게 섞여 있을 수록 Entropy 가 커지고, 하나의 클래스만 존재하면 불확실성이 전혀 없는 entropy 가 0 이 됨, 부모(전체 데이터가 섞여 있는 상태)라면 불확실성이 큰 상태이고 만약 특정 feature 로 분할해보니 데이터 그룹의 섞임이 줄었다면 Information Gain 이 증가된다면 분할

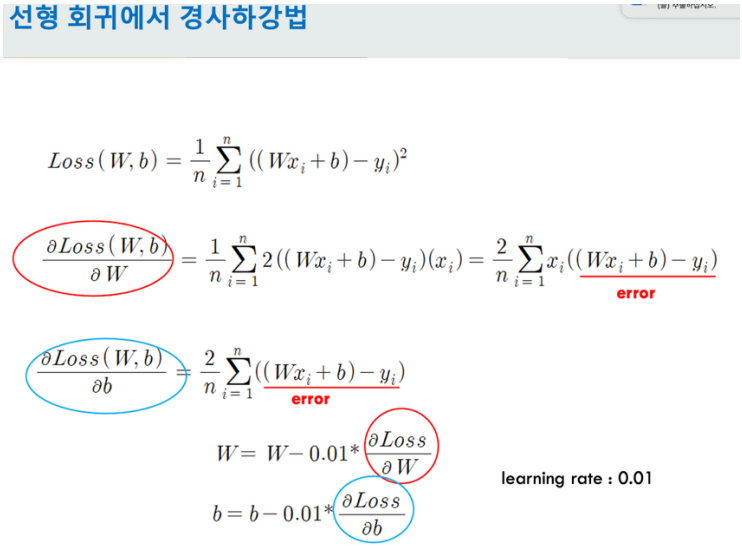
   $Entropy: -\sum_i p_i log(p_i)$ (p_i는 i 클래스의 확률) (**9-1, 14page 참조**)

3. [용어] 선형 회귀는 무엇을 찾는 것인 지 의미 알기 (독립 변수(예측값에 영향을 미치는 특징들)-종속변수(예측값) 사이의 상관 관계를 잘 설명할 수 있는 직선형태의 함수를 찾는 것으로, 주로 입력 속성을 가지고 수치값을 예측할 때 사용하는 대표적인 지도학습 (9-2), 비용함수/손실함수와 옵티마이징에 대한 설명을 써놓고 용어 넣기 (10-1)
4. [계산] 핸드폰 사용시간(x)과 시험 점수(y) 간 상관관계 선형회귀 예측(데이터가 주어짐).선형 회귀 모델을 y=wx+b 로 설정하고, 초기 가중치, 절편을 주고, 손실 함수(L)를 MSE(mean square error/평균제곱오차)로 정의.

   $L = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y_i})^2$ (평균제곱오차)

   y_i: i번째 학습 데이터의 정답(실제값), $\hat{y_i} = wx + b$ (모델의 i 번째 학습 데이터 대한 선형 모델의 예측값)

   이 때, 학습률 α=0.1 일 때 첫 번째(혹은 두번째, 세번째) 데이터에 대한 선형 회귀 모델의 예측값, 오차, 손실 함수의 w 에 대한 미분값을 이용해 w 를 gradient descent 방법으로 새롭게 업데이트 되어 구해진(갱신된) w 값 구하기.



5. [용어] KNN(K-nearest neighbors) 알고리즘에 대해 설명해 놓고 중간에 용어 채워 넣기, K-means 의 핵심 개념을 설명해 놓고 중간에 용어 채워넣기,
   KNN 은 **지도 학습** 방법으로 가장 가까운 K 개의 예제를 찾아 그 들의 클래스중 다수결(가장 많은 클래스)에 따라 새로운 데이터를 분류한다는 것 알기
   K-means 는 **비지도 학습** 알고리즘으로 정답이 없는 데이터들을 비슷한 것끼리 자동으로 군집화하며, K-means 의 동작 원리를 말로 설명해 가면서 계산 및 용어 채우기
   [계산] K-means 과정에 대한 이해, 중심점 계산 및 데이터와 중심점 사이의 유클리디언 거리 계산 알기. (유클리디언 거리는 2 차원 공간 상의 두 점 (x1, y1), (x2, y2)를 가정한다면 $d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$) **10-2, BMI, 체력점수 가지고 군집화하는 예제**)

6. [용어] 퍼셉트론에 대해 설명하면서 중간중간에 용어 채워 넣기와 퍼셉트론의 한계 설명해 놓고 중간에 용어 채워 넣기, MLP(다층 퍼셉트론)은 초기 퍼셉트론의 한계를 극복하기 위해 입력층, 출력층 외에 은닉층(hidden layer)를 추가하고 활성화함수를 잘 설계해서 비선형문제를 해결하려고 했음 용어 채우기

7. MLP 이 XOR 문제를 어떻게 해결 했는 지 입력값(00, 01, 10, 11 과 가중치값, 임계값)이 주어졌을 때 출력값 계산해 나가면서 용어 채우기 (**11-2, 14 페이지 XOR 문제**)

8. [용어] 다층 퍼셉트론에 은닉층을 깊게 쌓은 것을 심층 신경망 (DNN, Deep Neural Network)이라고 하는데 초기에는 가중치를 학습 시킬 방법이 없었다. 추후 오류 역전파 (backprogation)알고리즘이 등장해서 연쇄적인 미분(chain rule)을 통해 출력층의 오차로부터 역방향으로 각 층의 가중치에 대한 미분값을 구할 수 있게 되어 가중치 학습이 가능해 짐. 초기 활성화 함수로는 sigmoid 함수가 많이 사용되었는데 이것의 장점과 단점은 무엇이고 이를 극복하기 위해 ReLu 와 같은 활성화 함수가 사용되었는 지와 관련해서 설명 써놓고 중간에 용어 채우기

9. [용어] CNN(합성곱 신경망, Convolution Neural Network)에 대해 설명해 가면서 중간에 적절한 용어 채워 넣기, 풀링(max pooling, average pooling), 스트라이드, 패딩, feature map, 컨볼루션 연산, 필터/커널 등 중간고사의 내용과 마지막 분류 모델로 넘어가기 전의 feature_map 이 의미하는 바에 대해 설명해 가면서 적절한 용어 채우기

10. [용어] 객체 탐지/검출 (object detection) 에 대한 설명 후 중간에 용어 넣기 : 특정 이미지에서 경계 상자 bounding box 로 영역을 설정하고, 해당 영역 내에 물체가 존재하는지, 존재한다면 그 물체가 무엇인지 판별하는 일로 개별 객체의 영역을 구분하는 기능과 함께 분류까지 하는 것

11. [용어] 단어 수치 벡터 embedding : 2가지 방법 one-hot-encoding은 무엇이고 그 단점은, 또 단어를 주변단어를 고려해 의미적 특성을 반영해서 embedding하는 word2vec에 용어 채우기, word2vec과 같은 임베딩을 하면 유사도 계산이 쉽지만 임베딩 벡터가 정적이어서 한번 만들어지면 단어들은 모든 문장에서 동일한 임베딩 벡터값을 가짐

12. [계산] 간단한 문장과 각 단어에 대해 Key, Value, Query 벡터값을 주고 transformer 모델의 근간이 되는 self-attention 을 이용한 embedding vector 를 만드는 계산 과정을 설명해 가면서 핵심 개념 용어와 계산값 채우기 (**14-1 끝 14-2 초**) (중간에 필요한 식과 중간값은 계산하기 쉽게 미리 제공됨, Softmax 를 구하기 위한 e 값도 미리 계산되어 주어짐)

13. [용어] Transfer learning(전이학습), fine-tuning(파인 튜닝), pretrained(사전 학습) model, LLM(large langue model/거대언어모델), transformer에 대해 설명해 놓고 용어 채우기
    전이학습: 큰 대규모의 데이터 셋에서 이미 학습된 모델(pretrained model, 사전 학습 모델/weight들)을 가져다가 자신의 데이터를 추가해서 weight들을 미세조정(파인튜닝)해서 자신의 데이터에서도 문제를 잘 풀 수 있게 하는 방법